Реализовать схему тестового кластера:



Установка ssh:

sudo apt-get install ssh

Установка java:

sudo apt-get install openjdk-8-jdk

Создание отдельной учетной записи для запуска hadoop:

sudo addgroup hadoop sudo adduser --ingroup hadoop hduser sudo usermod -aG sudo hduser

Редактирование файла /etc/hosts

sudo nano /etc/hosts

Далее заходим и продолжаем под hduser

Получение SSH ключей

ssh-keygen -t rsa

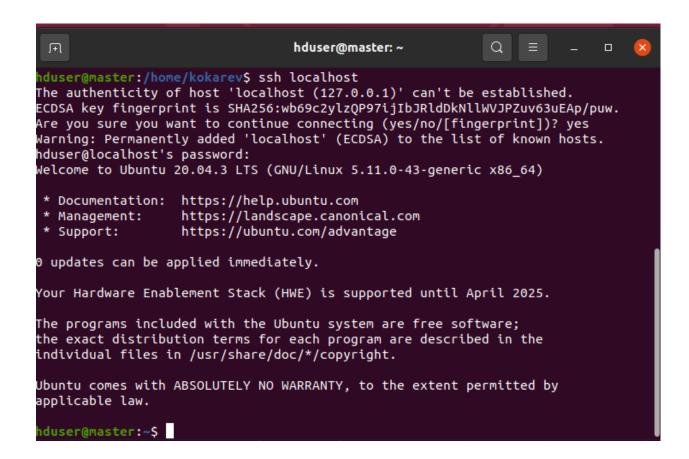
```
hduser@master: /home/kokarev
                                                            Q
hduser@master:~$ cd /home/kokarev
hduser@master:/home/kokarev$ ssh-keygen -t rsa
Generating public/private rsa key pair.
Enter file in which to save the key (/home/hduser/.ssh/id_rsa):
Enter passphrase (empty for no passphrase):
Enter same passphrase again:
Your identification has been saved in /home/hduser/.ssh/id_rsa
Your public key has been saved in /home/hduser/.ssh/id_rsa.pub
The key fingerprint is:
SHA256:nKCIh+BPx96pXtuw/++OypzBTKUD+ra1DqMfunu7ZXI hduser@master
The key's randomart image is:
+---[RSA 3072]----+
00 ....0..0
0.0..+ S+
 .0 0 0 = .
    . . % E
     .B=B=Xoo++
 ----[SHA256]----+
hduser@master:/home/kokarev$
```

Перемещаем полученные ключи:

```
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
chmod 0600 ~/.ssh/authorized_keys
```

Проверка подключения по ssh (ssh localhost)

ssh localhost



Установка Apache Hadoop

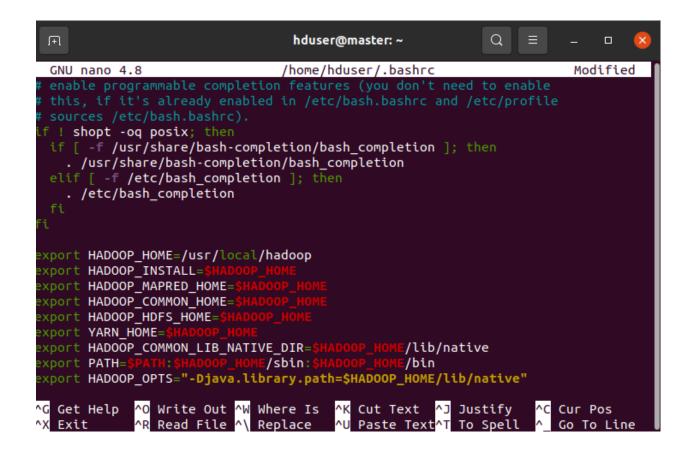
wget https://downloads.apache.org/hadoop/common/hadoop-3.3.0/hadoop-3.3.0.tar.gz tar -xvzf hadoop-3.3.0.tar.gz

Затем переместим извлеченный каталог в :/usr/local/

sudo mv hadoop-3.3.0 /usr/local/Hadoop
sudo mkdir /usr/local/hadoop/logs
sudo chown -R hduser:hadoop /usr/local/Hadoop

Настройтка Apache Hadoop:

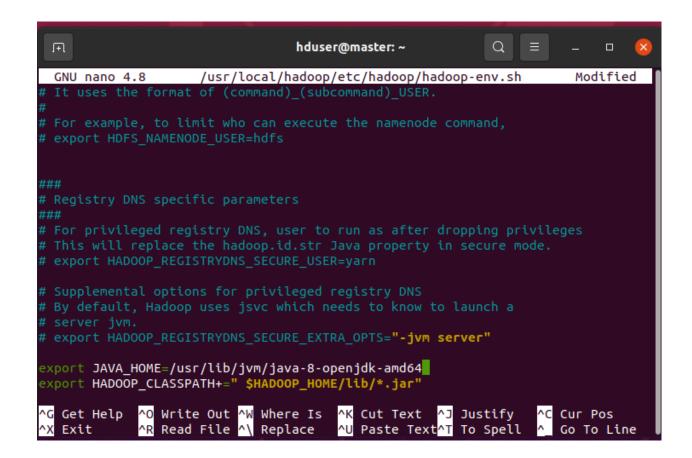
Настройка переменных среды в файле ~/.bashrc sudo nano ~/.bashrc



source ~/.bashrc

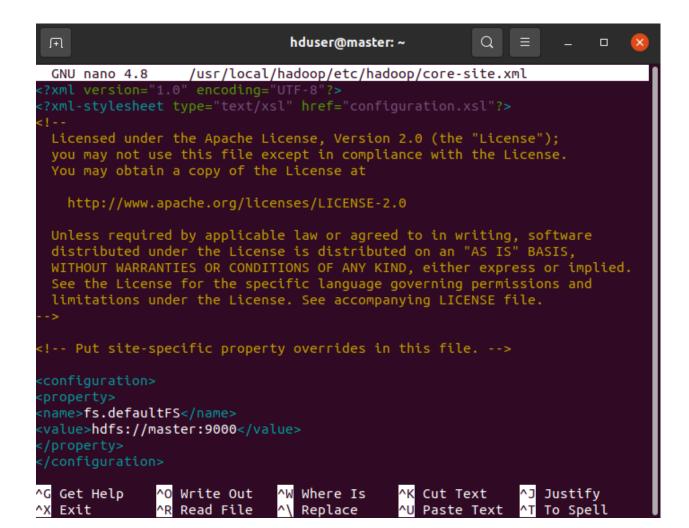
Затем нужно определить переменные среды Java, чтобы настроить параметры проекта, связанные с YARN, HDFS, MapReduce и Hadoop:hadoopenv.sh

sudo nano \$HADOOP\_HOME/etc/hadoop/hadoop-env.sh

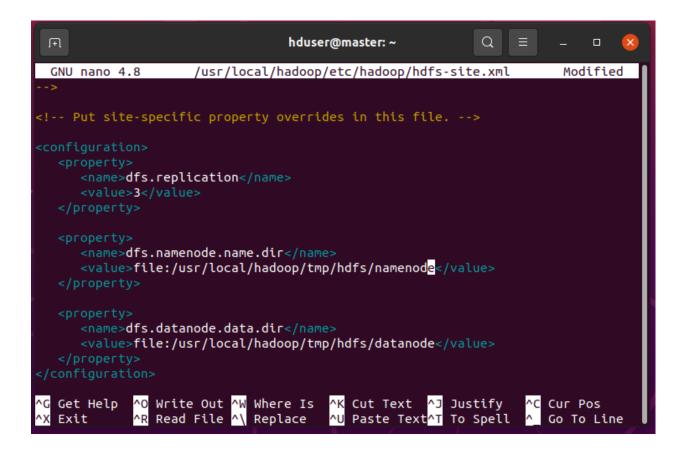


Настройка файлов

sudo nano /usr/local/hadoop/etc/hadoop/core-site.xml



sudo nano /usr/local/hadoop/etc/hadoop/hdfs-site.xml



sudo nano /usr/local/hadoop/etc/hadoop/mapred-site.xml

```
hduser@master: ~
GNU nano 4.8
                                          /usr/local/hadoop/etc/hadoop/mapred-site.xml
  Put site-specific property overrides in this file.
               <name>mapreduce.framework.name
               <value>yarn</value>
               <name>yarn.app.mapreduce.am.env
               <value>HADOOP_MAPRED_HOME=$HADOOP_HOME</value>
               <name>mapreduce.map.env</name>
               <value>HADOOP_MAPRED_HOME=$HADOOP_HOME</value>
               <name>mapreduce.reduce.env</name>
               <value>HADOOP_MAPRED_HOME=$HADOOP_HOME</value>
               <name>yarn.app.mapreduce.am.resource.mb
               <value>2048</value>
               <name>mapreduce.map.memory.mb
               <value>1024</value>
               <name>mapreduce.reduce.memory.mb
               <value>1024</value>
```

```
-- Site specific YARN configuration properties -->
              <name>yarn.acl.enable
              <value>0</value>
       property>
              <name>yarn.resourcemanager.hostname
              <value>master</value>
              <name>yarn.nodemanager.aux-services
              <value>mapreduce_shuffle</value>
               <name>yarn.nodemanager.resource.memory-mb
               <value>2048</value>
               <name>yarn.scheduler.maximum-allocation-mb
               <value>2048</value>
          </property>
               <name>yarn.scheduler.minimum-allocation-mb
               <value>1024</value>
          </property>
              <name>yarn.nodemanager.vmem-check-enabled
              <value>false</value>
```

Добавим на узле master все рабочие узлы в файл etc/hadoop/workers sudo nano /usr/local/hadoop/etc/hadoop/workers

```
GNU nano 4.8 /usr/local/hadoop/etc/hadoop/workers
master
node1
node2
```

## Форматирование HDFS NameNode

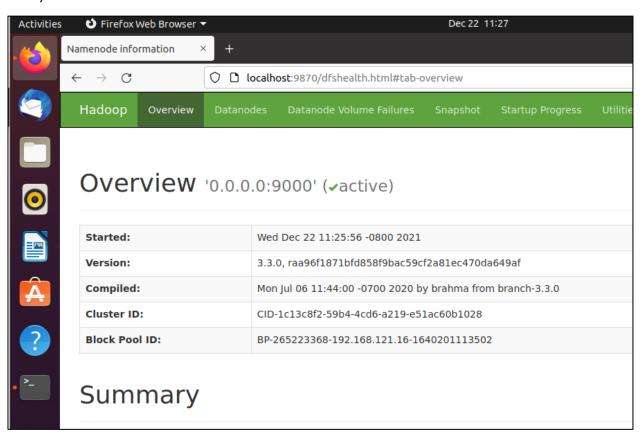
su - hduser

hdfs namenode -format

Запуск кластера Hadoop

start-dfs.sh

start-yarn.sh



## Задание 1:

На мастере:

Каталог namenode создался автоматически

Создаем каталог datanode

sudo mkdir -p /usr/local/hadoop/tmp/hdfs/datanode

форматируем файловую систему:

hdfs namenode -format

Копируем виртуальную машину мастера два раза – это будут узлы node1 и node2

Настраиваем имена узлов и ір адреса

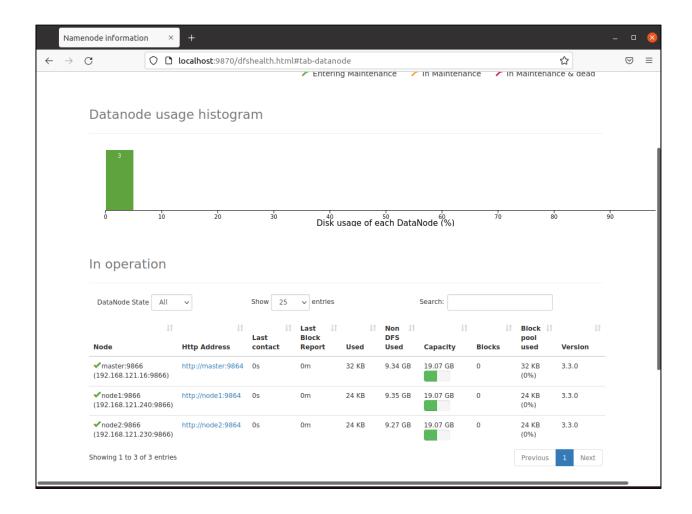
Запускаем start-dfs.sh и start-yarn.sh на мастере

Проверяем количество узлов:

hdfs dfsadmin -report

```
hduser@master:~$ hdfs dfsadmin -report
Configured Capacity: 61415964672 (57.20 GB)
Present Capacity: 28200980480 (26.26 GB)
DFS Remaining: 28200890368 (26.26 GB)
DFS Used: 90112 (88 KB)
DFS Used%: 0.00%
Replicated Blocks:
        Under replicated blocks: 0
        Blocks with corrupt replicas: 0
        Missing blocks: 0
        Missing blocks (with replication factor 1): 0
        Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
Erasure Coded Block Groups:
        Low redundancy block groups: 0
        Block groups with corrupt internal blocks: 0
        Missing block groups: 0
        Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
Live datanodes (3):
```

Переходим в браузер:



## Задание 2.

Подключаемся по ssh с мастера к node1

## ssh node1

```
hduser@master:~$ ssh node1
Welcome to Ubuntu 20.04.3 LTS (GNU/Linux 5.11.0-43-generic x86_64)

* Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

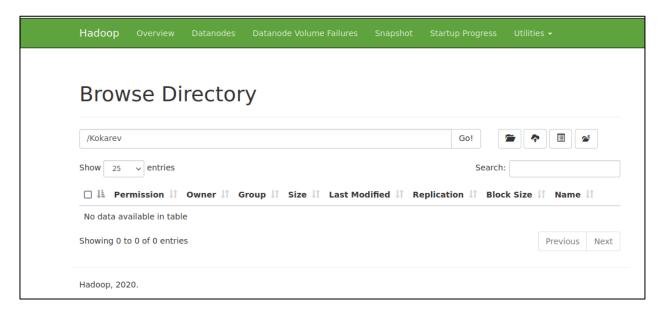
* Support: https://ubuntu.com/advantage

0 updates can be applied immediately.

Your Hardware Enablement Stack (HWE) is supported until April 2025.
Last login: Wed Dec 22 12:25:13 2021 from 192.168.121.16
```

Создаем папку

hadoop fs -mkdir hdfs://master:9000/Kokarev



Создаем файл и кладем в ранее созданную папку:

hadoop fs -put /home/hduser/Desktop/ttt/test.txt hdfs://master:9000/Kokarev

