Лабораторная работа №3. Кокарев Д. В. РИМ-201211

Задание 0

1. Открыть презентацию по HIVE и повторить команды со слайдов про Mapreduce\YARN.

export YARN_EXAMPLES=${HADOOP_HOME}/share/hadoop/mapreduce

yarn jar ${YARN_EXAMPLES}/hadoop-mapreduce-examples-3.3.0.jar

```
hduser@master:~$ export YARN_EXAMPLES=${HADOOP_HOME}/share/hadoop/mapreduce
hduser@master:~$
hduser@master:~$ yarn jar ${YARN_EXAMPLES}/hadoop-mapreduce-examples-3.3.0.jar
An example program must be given as the first argument.
Valid program names are:
  aggregatewordcount: An Aggregate based map/reduce program that counts the words in the input files.
  aggregatewordhist: An Aggregate based map/reduce program that computes the histogram of the words in the input files.
  bbp: A map/reduce program that uses Bailey-Borwein-Plouffe to compute exact digits of Pi.
  dbcount: An example job that count the pageview counts from a database.
  distbbp: A map/reduce program that uses a BBP-type formula to compute exact bits of Pi.
  grep: A map/reduce program that counts the matches of a regex in the input.
  join: A job that effects a join over sorted, equally partitioned datasets
  multifilewc: A job that counts words from several files.
  pentomino: A map/reduce tile laying program to find solutions to pentomino problems.
  pi: A map/reduce program that estimates Pi using a quasi-Monte Carlo method.
  randomtextwriter: A map/reduce program that writes 10GB of random textual data per node.
  randomwriter: A map/reduce program that writes 10GB of random data per node.
  secondarysort: An example defining a secondary sort to the reduce.
  sort: A map/reduce program that sorts the data written by the random writer.
  sudoku: A sudoku solver.
  teragen: Generate data for the terasort
  terasort: Run the terasort
  teravalidate: Checking results of terasort
  wordcount: A map/reduce program that counts the words in the input files.
  wordmean: A map/reduce program that counts the average length of the words in the input files.
  wordmedian: A map/reduce program that counts the median length of the words in the input files.
  wordstandarddeviation: A map/reduce program that counts the standard deviation of the length of the words in the input files.
hduser@master:~$
```

yarn jar ${YARN_EXAMPLES}/hadoop-mapreduce-examples-3.3.0.jar pi 16 10000

Результат выполнения:

```
Job Finished in 56.21 seconds
Estimated value of Pi is 3.14127500000000000000
hduser@master:~$
```

yarn jar ${YARN_EXAMPLES}/hadoop-mapreduce-examples-3.3.0.jar pi 16 100000

Результат выполнения:

```
Job Finished in 41.983 seconds
Estimated value of Pi is 3.14157500000000000000
hduser@master:~$
```

2. Выполнить пример расчёта pi с числом сэмплов 1M.

yarn jar ${YARN_EXAMPLES}/hadoop-mapreduce-examples-3.3.0.jar pi 16 1000000

Результат выполнения:

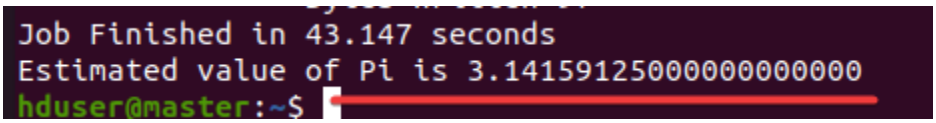

3. Записать в отчёт полученное значение.

Полученное значение Pi: 3.14159125000000000000

Задание 1.

Для начала выполним настройку:

Добавим строки в файл /.bashrc на master, node1, node2:

export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64

export PATH=${JAVA_HOME}/bin:${PATH}

export HADOOP_CLASSPATH=${JAVA_HOME}/lib/tools.jar

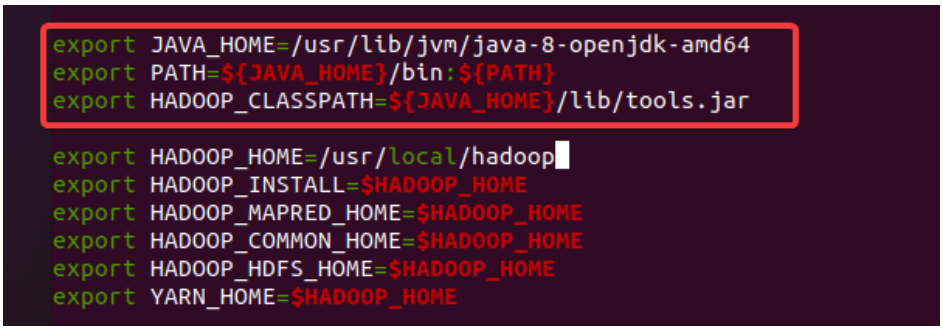

После редактирования файла не забываем выполнить команду: source ~/.bashrc

На мастере создаем файл /usr/local/hadoop/WordCount.java и копируем в него строки из примера wordcount:

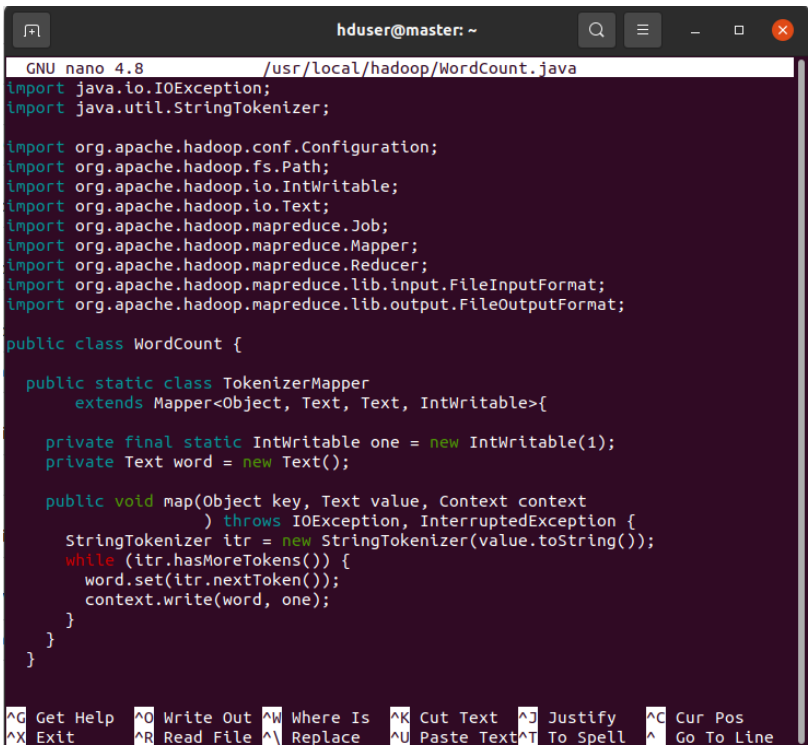

Далее необходимо скомпилировать java файл, командами:

hadoop com.sun.tools.javac.Main WordCount.java

jar cf wc.jar WordCount*.class

```
hduser@master:~$ cd /usr/local/hadoop
hduser@master:/usr/local/hadoop$ hadoop com.sun.tools.javac.Main WordCount.java
hduser@master:/usr/local/hadoop$ jar cf wc.jar WordCount*.class
hduser@master:/usr/local/hadoop$
```

1. Подготовьте тестовые папки в HDFS для запуска задачи и положите в папку input любой текстовый файл для анализа

hadoop fs -mkdir -p /user/hadoop/wordcount/input

hadoop fs -mkdir -p /user/hadoop/wordcount/output

```
hduser@master:~$ hadoop fs -mkdir -p /user/hadoop/wordcount/input
hduser@master:~$ hadoop fs -mkdir -p /user/hadoop/wordcount/output
```

Положим в папку input подготовленный текстовый файл:

hadoop fs -put /home/hduser/Desktop/ttt/textfile.txt /user/hadoop/wordcount/input

```
hduser@master:~$ hadoop fs -put /home/hduser/Desktop/ttt/textfile.txt /user/hado
op/wordcount/input
```

2. Запустите пример wordcount по аналогии с примером выше.

hadoop jar wc.jar WordCount /user/hadoop/wordcount/input /user/hadoop/wordcount/output

Во время запуска Hadoop заругался на уже существующую директорию output. Поэтому поместим результат в output1.

Выполняем еще раз:

hadoop jar wc.jar WordCount /user/hadoop/wordcount/input /user/hadoop/wordcount/output1

3. После завершения просмотрите результаты в папке output и в отчёт включите несколько первых строк из файла результата (обычно называется part-r-00000)/

hadoop fs -cat /user/hadoop/wordcount/output1/part-r-00000

```
hduser@master:~$ hadoop fs -cat /user/hadoop/wordcount/output1/part-r-00000
&amp;   1
-->     2
/>      14
<!--    2
</datatypes><table      1
</group>        4
</key>  13
</row>  14
</sql>  1
</table>        13
<?xml   1
<datatype>DATE</datatype>       1
<datatype>INTEGER</datatype>    61
<datatype>MEDIUMTEXT</datatype> 2
<datatypes      1
<default>NULL</default></row>   50
<default>NULL</default><relation        14
<group  4
<key    13
<part>id</part> 13
<       64
Help
<       1
```